Modelul Bag-of-Words. Clasificatorul SVM.

În acest laborator vom clasifica texte traduse dintr-un dialect (englez, scoțian sau irlandez) în cinci limbi diferite (daneză, olandeză, spaniolă, italiană și germană) (tema voastră la proiect) folosind modelul Bag-of-Words („sac de cuvinte”) pentru reprezentarea textelor și clasificatorul SVM predat la curs.

1. Modelul Bag-of-Words (BOW)

Modelul Bag-of-words este o reprezentare simplificată a textelor folosită în procesarea limbajului natural și în regăsirea informației. Conform acestui model, reprezentăm un text numărând de câte ori apare un cuvânt dintr-un anumit dicționar în textul respectiv. Prin folosirea unei asemenea reprezentări, informația legată de ordinea cuvintelor, gramatică, topică, sensul cuvintelor se pierde.

Exemplu[1]: considerăm textele 1 și 2 de mai jos în limba engleză.

```
(1) John likes to watch movies. Mary likes movies too.
(2) John also likes to watch football games.
```

Eliminând semnele de punctuație obținem listele de cuvinte pentru cele două texte:

```
"John","likes","to","watch","movies","Mary","likes","movies","too"
"John","also","likes","to","watch","football","games"
```

Considerăm dicționarul D format din reuniunea tuturor cuvintelor din cele 2 texte:

```
D = {"John","likes","to","watch","movies","Mary","too", "also",
"football", "games"}
```

Reprezentăm fiecare text numărând de câte ori apare fiecare cuvânt din dicționarul D în fiecare text. Obținem reprezentările bag-of-words următoare:

```
BoW1 = {"John":1, "likes":2, "to":1, "watch":1, "movies":2, "Mary":1,
"too":1, "also":0, "football":0, "games":0};

BoW2 = {"John":1, "likes":1, "to":1, "watch":1, "movies":0, "Mary":0,
"too":0, "also":1, "football":1, "games":1};
```

Pentru dicționarul D fixat, reprezentările se pot scrie sub forma de vectori de frecvențe:

```
v1 = [1, 2, 1, 1, 2, 1, 1, 0, 0, 0];
```

[1] https://en.wikipedia.org/wiki/Bag-of-words_model

```
v2 = {1, 1, 1, 1, 0, 0, 0, 1, 1, 1};
```

Suma elementelor fiecarui vector reprezintă numărul de cuvinte din text. De obicei, pentru probleme de clasificare în care încercăm să discriminăm între texte de diferite lungimi se folosesc reprezentări normalizate. Spre exemplu, folosind norma L_1 (suma absolută a elementelor unui vector) obținem vectorii normalizați L_1:

$$v1_{L1} = \frac{v1}{\|v1\|_1} = \left[\frac{1}{9}, \frac{2}{9}, \frac{1}{9}, \frac{1}{9}, \frac{2}{9}, \frac{1}{9}, \frac{1}{9}, 0, 0, 0\right]$$

$$v2_{L1} = \frac{v2}{\|v2\|_1} = \left[\frac{1}{7}, \frac{1}{7}, \frac{1}{7}, \frac{1}{7}, 0, 0, 0, \frac{1}{7}, \frac{1}{7}, \frac{1}{7}\right]$$

Folosind norma L_2 (norma Euclidiană) obținem vectorii normalizați L_2:

$$v1_{L2} = \frac{v1}{\|v1\|_2} = \left[\frac{1}{\sqrt{13}}, \frac{2}{\sqrt{13}}, \frac{1}{\sqrt{13}}, \frac{1}{\sqrt{13}}, \frac{2}{\sqrt{13}}, \frac{1}{\sqrt{13}}, \frac{1}{\sqrt{13}}, 0, 0, 0\right]$$

$$v2_{L2} = \frac{v2}{\|v2\|_2} = \left[\frac{1}{\sqrt{7}}, \frac{1}{\sqrt{7}}, \frac{1}{\sqrt{7}}, \frac{1}{\sqrt{7}}, 0, 0, 0, \frac{1}{\sqrt{7}}, \frac{1}{\sqrt{7}}, \frac{1}{\sqrt{7}}\right]$$

2. Clasificatorul SVM

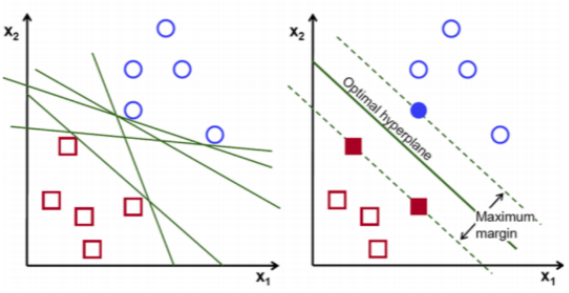

Clasificatorul SVM încearcă să separe clase folosind un hiperplan de margine maximă (figura alăturată prezintă cazul binar, cu două clase).

Pentru implementarea acestui algoritm vom folosi biblioteca ***scikit-learn***. Aceasta este dezvoltată în Python, fiind integrată cu NumPy și pune la dispoziție o serie de algoritmi optimizați pentru probleme de clasificare, regresie și clusterizare. Instalarea bibliotecii se face prin comanda sistem: ***pip install -U scikit-learn.***

2.1 Detalii de implementare

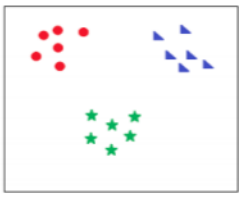

Există două abordări pentru a clasifica datele aparținând mai multor clase: (1) one vs all și (2) one vs one.Vom exemplifica aceste două abordări pentru datele din figura alăturată, considerând exemplele din $n = 3$ clase.

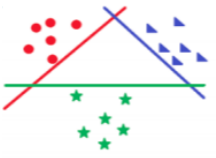

Abordarea *one vs all*: sunt antrenați n clasificatori, câte unul corespunzător fiecărei clase, care să o diferențieze pe aceasta de toate celelalte (toate celelalte exemple sunt privite ca aparținând aceleiași clase). Eticheta finală pentru un exemplu nou va fi dată de clasificatorul care a obținut scorul maxim.

Abordarea *one vs one* (implicită în scikit-learn): sunt antrenați $n \times (n\text{-}1)/2$ clasificatori câte unul corespunzător fiecarei perechi de câte două clase. Eticheta finală pentru un exemplu nou va fi cea care obține cele mai multe voturi pe baza acestor clasificatori.

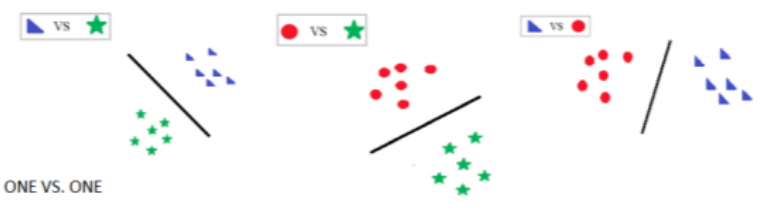

2.2 Implementarea în scikit-learn

1. *Definirea modelului* se realizează folosind comanda:
   svm_model = ***sklearn.svm.SVC***(C, kernel, …)

2. *Antrenarea modelului* se realizează folosind comanda:
   svm_model***.fit***(train_data, train_labels)

3. *Predicția modelului* pentru exemple de testare se realizează folosind comanda:
   predicted_labels = svm_model***.predict***(test_data)

unde:

parametrul C (float, default = 1.0) reprezintă parametrul de penalitate pentru eroarea făcută de model pe exemplele de antrenare. Valoarea lui C influențează alegerea hiperplanului optim de separare. Pentru valori mari ale lui C va fi ales un hiperplan cu o margine mai mică dar cu acuratețe cât mai mare a clasificării pe exemplele din mulțimea de antrenare. Pentru valori mai mici ale lui C va fi ales un hiperplan cu o margine mai mare, chiar dacă acesta duce la clasificarea greșită a unor exemple din mulțimea de antrenare.

parametrul kernel (string, default = 'linear') reprezintă tipul de funcție nucleu ales pentru modelarea suprafeței de decizie a clasificatorului. Implicit, este ales kernelul liniar, care definește un hiperplan. Alte valori definesc suprafețe neliniare: rbf, poly, etc.

parametrul train_data reprezintă mulțimea exemplelor de antrenare, stocată sub forma unei matrice, pe fiecare linie se află un exemplu de antrenare având drept componente caracteristicile extrase.

parametrul train_data reprezintă etichetele corespunzătoare fiecărui exemplu de antrenare din matricea, sub forma unui vector coloană.

parametrul test_data reprezintă mulțimea exemplelor de testare, stocate sub forma unei matrice, pe fiecare linie se află un exemplu de testare având drept componente caracteristicile extrase.

3. Clasificarea textelor folosind modelul BOW și clasificatorul SVM

Problema pe care o aveți de rezolvat în acest laborator este similară cu problema pe care o aveți de rezolvat la proiect. Veți clasifica texte traduse în cinci limbi diferite (daneză, olandeză, spaniolă, italiană și germană) dintr-un anumit dialect (englez, scoțian sau irlandez) . Veți lucra în cadrul acestui laborator numai cu exemplele de antrenare de la proiect, întrucât pentru ele aveți etichetele. Exemplele de antrenare sunt în număr total de 41570 texte traduse

în cele cinci limbi dintr-unul din cele 3 dialecte. În rezolvarea problemei de la acest laborator veți folosi modelul Bag-of-Words pentru reprezentarea textelor și clasificatorul SVM.

Codul de la care porniți în acest laborator citește traducerile din cele cinci limbi și împarte cele 41570 de traduceri inițiale (care alcătuiesc exemplele de antrenare pentru proiectul vostru) în trei submulțimi: 28268 de exemple de antrenare, 4988 de exemple de validare și 8314 de exemple de testare. Este important să remarcați că aveți etichete pentru toate aceste exemple și puteți evalua astfel performanța unui clasificator. Pentru proiectul vostru de pe Kaggle nu aveți etichetele pentru exemplele de test. Codul de la care porniți elimină semnele de punctație reprezentând inițial textele ca liste de cuvinte (tokens) apoi calculează cele mai frecvente 1000 de cuvinte care apar în cele 2000 exemple de antrenare și care vor forma dicționarul vostru (variabila *small_dictionary*).

Realizați următoarele:

1. Scrieți codul Python care calculează reprezentarea BOW pentru o matrice de exemple în funcție de cuvintele din dicționarul *small_dictionary*. Normalizați această reprezentare în funcție de norma L_2. Pentru fiecare exemplu de text (antrenare, validare, testare) reprezentarea BOW a sa va fi dată de un vector linie de 1000 de componente. Reprezentarea BOW a matricei de exemple de antrenare va avea astfel dimensiunile 2000×1000. Reprezentarea normalizată are proprietatea că fiecare linie are norma L_2 egală cu 1.
2. Extrageți reprezentările BOW normalizate L_2 pentru exemplele de antrenare, validare, testare.
3. Antrenați mai mulți clasificatori SVM liniari pe exemplele de antrenare folosind diverse valori pentru C. Spre exemplu puteți încerca valori din mulțimea {0.001, 0.01, 0.1, 1, 10, 100}. Alegeți cel mai bun clasificator SVM dintre cei antrenați, cel care are acuratețea cea mai mare pe mulțimea de exemple de validare.
4. Care este acuratețea clasificatorului vostru pe mulțimea de exemple de testare de 493 de exemple?